

# Statistique Mathématique

## Chapitre 5: Estimation

**Mohamed Essaied Hamrita**

**Mastère de Recherche: Finance & Actuariat**  
**IHEC Sousse**

Décembre 2022



Institut des Hautes Etudes Commerciales de Sousse  
معهد الدراسات العليا التجارية بسوسة

- ① Vocabulaires
- ② Propriétés d'un estimateur
- ③ Méthodes d'estimation

# ① Vocabulaires

## ② Propriétés d'un estimateur

## ③ Méthodes d'estimation

Soit  $X$  une variable aléatoire de densité  $f(x, \theta)$  où  $\theta$  est un paramètre inconnu. Soit  $(x_1, x_2, \dots, x_n)$  un  $n$ -échantillon *i.i.d* issu de la loi de  $X$ .  
Comment estimer le paramètre  $\theta$ ?

Soit  $X$  une variable aléatoire de densité  $f(x, \theta)$  où  $\theta$  est un paramètre inconnu. Soit  $(x_1, x_2, \dots, x_n)$  un  $n$ -échantillon *i.i.d* issu de la loi de  $X$ . Comment estimer le paramètre  $\theta$ ?

## Définition 1

*Un estimateur ponctuel est toute fonction  $T(x_1, x_2, \dots, x_n)$  d'un échantillon. Toute statistique est estimateur ponctuel.*

Soit  $X$  une variable aléatoire de densité  $f(x, \theta)$  où  $\theta$  est un paramètre inconnu. Soit  $(x_1, x_2, \dots, x_n)$  un  $n$ -échantillon *i.i.d* issu de la loi de  $X$ . Comment estimer le paramètre  $\theta$ ?

## Définition 1

*Un estimateur ponctuel est toute fonction  $T(x_1, x_2, \dots, x_n)$  d'un échantillon. Toute statistique est estimateur ponctuel.*

## Exemple 1

*Soit  $(X_1, X_2, \dots, X_n)$  un  $n$ -échantillon *i.i.d* issu de la loi normale de paramètres  $m$  et  $\sigma^2$ .*

-  $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$  est un estimateur ponctuel du paramètre  $m$ .

Soit  $X$  une variable aléatoire de densité  $f(x, \theta)$  où  $\theta$  est un paramètre inconnu. Soit  $(x_1, x_2, \dots, x_n)$  un  $n$ -échantillon *i.i.d* issu de la loi de  $X$ . Comment estimer le paramètre  $\theta$ ?

## Définition 1

*Un estimateur ponctuel est toute fonction  $T(x_1, x_2, \dots, x_n)$  d'un échantillon. Toute statistique est estimateur ponctuel.*

## Exemple 1

*Soit  $(X_1, X_2, \dots, X_n)$  un  $n$ -échantillon *i.i.d* issu de la loi normale de paramètres  $m$  et  $\sigma^2$ .*

-  $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$  est un estimateur ponctuel du paramètre  $m$ .

-  $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$  est un estimateur ponctuel du paramètre  $\sigma^2$ .

### ③ Méthodes d'estimation



Un estimateur  $\hat{\theta}$  est **une variable aléatoire**.

Un estimateur  $\hat{\theta}$  est **une variable aléatoire**.

**conséquences:**

- $\hat{\theta}$  possède une distribution de probabilité **empirique**.

Un estimateur  $\hat{\theta}$  est **une variable aléatoire**.

**conséquences:**

- $\hat{\theta}$  possède une distribution de probabilité **empirique**.
- La distribution empirique de  $\hat{\theta}$  est caractérisée par les moments tels que  $\mathbb{E}(X)$ ,  $\mathbb{V}(X)$  et  $\mathbb{E}(X^k)$ .

Un estimateur  $\hat{\theta}$  est **une variable aléatoire**.

**conséquences:**

- $\hat{\theta}$  possède une distribution de probabilité **empirique**.
- La distribution empirique de  $\hat{\theta}$  est caractérisée par les moments tels que  $\mathbb{E}(X)$ ,  $\mathbb{V}(X)$  et  $\mathbb{E}(X^k)$ .

Un estimateur  $\hat{\theta}$  est **une variable aléatoire**.

**conséquences:**

- $\hat{\theta}$  possède une distribution de probabilité **empirique**.
- La distribution empirique de  $\hat{\theta}$  est caractérisée par les moments tels que  $\mathbb{E}(X)$ ,  $\mathbb{V}(X)$  et  $\mathbb{E}(X^k)$ .

## Définition 2

*Les propriétés d'un estimateur  $\hat{\theta}$  correspondent aux propriétés de sa densité empirique définie pour un échantillon de taille  $n \in \mathbb{N}$ .*

Un estimateur  $\hat{\theta}$  est **une variable aléatoire**.

### conséquences:

- $\hat{\theta}$  possède une distribution de probabilité **empirique**.
- La distribution empirique de  $\hat{\theta}$  est caractérisée par les moments tels que  $\mathbb{E}(X)$ ,  $\mathbb{V}(X)$  et  $\mathbb{E}(X^k)$ .

## Définition 2

*Les propriétés d'un estimateur  $\hat{\theta}$  correspondent aux propriétés de sa densité empirique définie pour un échantillon de taille  $n \in \mathbb{N}$ .*

## Exemple 2

*Soit  $(X_1, X_2, \dots, X_n)$  un  $n$ -échantillon i.i.d issu de la loi normale de paramètres  $m$  et  $\sigma^2$ .  $\hat{m} = \bar{X} \sim \mathbb{N}(m, \frac{\sigma^2}{n})$ .*

## ① Vocabulaires

## ② Propriétés d'un estimateur

Estimateur sans biais

Estimateur convergent

Estimateur efficace

## ③ Méthodes d'estimation

## Définition 3

Un estimateur  $\hat{\theta}$  est dit **sans biais** si  $\mathbb{E}(\hat{\theta}) = \theta$ .



## Définition 3

Un estimateur  $\hat{\theta}$  est dit **sans biais** si  $\mathbb{E}(\hat{\theta}) = \theta$ .

## Exercice 1

Soit le modèle linéaire  $Y = X\beta + \varepsilon$ , où  $\varepsilon \sim N(0, \sigma^2 I_n)$ . Montrer que  $\hat{\beta} = (X'X)^{-1}X'Y$  est un estimateur sans biais de  $\beta$ .

## Définition 3

Un estimateur  $\hat{\theta}$  est dit **sans biais** si  $\mathbb{E}(\hat{\theta}) = \theta$ .

## Exercice 1

Soit le modèle linéaire  $Y = X\beta + \varepsilon$ , où  $\varepsilon \sim N(0, \sigma^2 I_n)$ . Montrer que  $\hat{\beta} = (X'X)^{-1}X'Y$  est un estimateur sans biais de  $\beta$ .

## Définition 4

Un estimateur  $\hat{\theta}$  est dit **asymptotiquement sans biais** si  $\lim_{n \rightarrow \infty} \mathbb{E}(\hat{\theta}) = \theta$ .

## Exercice 2

Soit  $S^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$  un estimateur de  $\sigma^2$  d'un échantillon i.i.d issu d'une loi normale de paramètres  $m$  et  $\sigma^2$ . Montrer que  $S^2$  est asymptotiquement sans biais.

## ① Vocabulaires

## ② Propriétés d'un estimateur

Estimateur sans biais

Estimateur convergent

Estimateur efficace

## ③ Méthodes d'estimation

## Définition 5

Un estimateur  $\hat{\theta}$  est dit **convergent** s'il est sans biais et  $\lim_{n \rightarrow \infty} \mathbb{V}(\hat{\theta}) = 0$ .

## Définition 5

Un estimateur  $\hat{\theta}$  est dit **convergent** s'il est sans biais et  $\lim_{n \rightarrow \infty} \mathbb{V}(\hat{\theta}) = 0$ .

## Exercice 3

Montrer que  $\hat{m} = \bar{X}$  est un estimateur convergent de  $m$

## Définition 5

Un estimateur  $\hat{\theta}$  est dit **convergent** s'il est sans biais et  $\lim_{n \rightarrow \infty} \mathbb{V}(\hat{\theta}) = 0$ .

## Exercice 3

Montrer que  $\hat{m} = \bar{X}$  est un estimateur convergent de  $m$

$$\begin{aligned}\mathbb{V}(\bar{X}) &= \mathbb{V}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) \\ &= \frac{1}{n^2} \sum_{i=1}^n \mathbb{V}(X_i) \\ &= \frac{\sigma^2}{n} \xrightarrow{n \rightarrow \infty} 0\end{aligned}$$

## ① Vocabulaires

## ② Propriétés d'un estimateur

Estimateur sans biais

Estimateur convergent

Estimateur efficace

## ③ Méthodes d'estimation

## Définition 6

Soit  $(X_1, X_2, \dots, X_n)$  un  $n$ -échantillon i.i.d de densité  $f(X_i, \theta)$  et soit  $\hat{\theta}$  un estimateur sans bias de  $\theta$ .  $\hat{\theta}$  est dit **efficace** si  $\mathbb{V}(\hat{\theta}) = I^{-1}(\theta)$  où  $I(\theta)$  est appelée **quantité d'information de Fisher**.

$I(\theta) = \mathbb{E} \left( (\partial L / \partial \theta)^2 \right) = -\mathbb{E} \left( \partial^2 L / \partial \theta^2 \right)$  avec  $L$  est la fonction log-vraisemblance (sera définie dans la section suivante).



## Définition 6

Soit  $(X_1, X_2, \dots, X_n)$  un  $n$ -échantillon i.i.d de densité  $f(X_i, \theta)$  et soit  $\hat{\theta}$  un estimateur sans bias de  $\theta$ .  $\hat{\theta}$  est dit **efficace** si  $\mathbb{V}(\hat{\theta}) = I^{-1}(\theta)$  où  $I(\theta)$  est appelée **quantité d'information de Fisher**.

$I(\theta) = \mathbb{E} \left( (\partial L / \partial \theta)^2 \right) = -\mathbb{E} \left( \partial^2 L / \partial \theta^2 \right)$  avec  $L$  est la fonction log-vraisemblance (sera définie dans la section suivante).

## Définition 7

Soient  $\hat{\theta}_1$  et  $\hat{\theta}_2$  deux estimateurs d'un paramètre  $\theta$ . On dit que  $\hat{\theta}_1$  est **plus efficace** que  $\hat{\theta}_2$  si  $\mathbb{V}(\hat{\theta}_1) \leq \mathbb{V}(\hat{\theta}_2)$ .

### 3 Méthodes d'estimation

## Méthode des MCO

## ① Vocabulaires

## ② Propriétés d'un estimateur

## ③ Méthodes d'estimation

### La méthode de vraisemblance

### Méthode des moments

### Méthode des MCO

## Définition 8 (La vraisemblance)

Soit  $(X_1, X_2, \dots, X_n)$  un  $n$ -échantillon i.i.d de densité  $f(X_i, \theta)$ . On appelle la fonction de vraisemblance la fonction  $L(x_1, x_2, \dots, x_n, \theta)$  définie par:

$$L(x_1, x_2, \dots, x_n, \theta) = \prod_{i=1}^n f(x_i, \theta)$$

## Définition 8 (La vraisemblance)

Soit  $(X_1, X_2, \dots, X_n)$  un  $n$ -échantillon i.i.d de densité  $f(X_i, \theta)$ . On appelle la fonction de vraisemblance la fonction  $L(x_1, x_2, \dots, x_n, \theta)$  définie par:

$$L(x_1, x_2, \dots, x_n, \theta) = \prod_{i=1}^n f(x_i, \theta)$$

En pratique, on utilise plutôt la fonction de log-vraisemblance qui est définie par:

$$\ell(x_1, x_2, \dots, x_n, \theta) = \ln L = \sum_{i=1}^n \ln(f(x_i, \theta))$$

## Exercice 4

*Déterminer le log-vraisemblance d'un  $n$ -échantillon i.i.d de loi de poisson de paramètre  $\theta$ .*

## Exercice 4

Déterminer le log-vraisemblance d'un  $n$ -échantillon *i.i.d* de loi de poisson de paramètre  $\theta$ .

$$\begin{aligned}
 \ell(x_1, x_2, \dots, x_n, \theta) &= \sum_{i=1}^n \ln(f(x_i, \theta)) = \sum_{i=1}^n \ln\left(\frac{e^{-\theta} \theta^{x_i}}{x_i!}\right) \\
 &= \sum_{i=1}^n \left[ \ln(e^{-\theta} \theta^{x_i}) - \ln(x_i!) \right] \\
 &= \sum_{i=1}^n \left[ -\theta + x_i \ln \theta - \sum_{i=1}^n \ln(x_i) \right] \\
 &= -n\theta + \ln \theta \sum_{i=1}^n x_i - n \sum_{i=1}^n \ln(x_i)
 \end{aligned}$$

## La fonction log-vraisemblance avec R

```
lPois=function(theta,x){  
  n=length(x)  
  ss=sum(x)  
  ss1=sum(log(factorial(x)))  
  -n*theta+ss*log(theta)-n*ss1  
}
```



## Définition 9

*L'estimateur du maximum de vraisemblance est celui qui maximise la fonction de vraisemblance:*

$$\hat{\theta}_{MV} = \arg \max_{\theta} \ell(x_1, x_2, \dots, x_n, \theta)$$

## Définition 9

*L'estimateur du maximum de vraisemblance est celui qui maximise la fonction de vraisemblance:*

$$\hat{\theta}_{MV} = \arg \max_{\theta} \ell(x_1, x_2, \dots, x_n, \theta)$$

Il s'agit d'un problème d'optimisation sans contraintes.

**Condition du premier ordre :** La dérivé (les dérivées partielles)

première(s) s'annule(nt), i.e;  $\frac{\partial \ell}{\partial \theta} = 0$ . Le vecteur colonne  $s(\theta, x) = \frac{\partial \ell}{\partial \theta}$  sera appelé la fonction score.

**Condition du second ordre:** La dérivée seconde est négative ( $\frac{\partial^2 \ell}{\partial \theta \partial \theta'}$  est définie négative)

## Remarque:

$$H = \frac{\partial^2 \ell}{\partial \theta \partial \theta'} = \begin{pmatrix} \frac{\partial^2 \ell}{\partial \theta_1^2} & \frac{\partial^2 \ell}{\partial \theta_1 \partial \theta_2} & \cdots & \frac{\partial^2 \ell}{\partial \theta_1 \partial \theta_k} \\ \frac{\partial^2 \ell}{\partial \theta_2 \partial \theta_1} & \frac{\partial^2 \ell}{\partial \theta_2^2} & \cdots & \frac{\partial^2 \ell}{\partial \theta_2 \partial \theta_k} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 \ell}{\partial \theta_k \partial \theta_1} & \cdots & \cdots & \frac{\partial^2 \ell}{\partial \theta_k^2} \end{pmatrix}$$

La matrice  $H$  est appelée matrice hessienne et elle est égale à l'opposé de l'inverse de la matrice des variances-covariance de  $\theta$ ,  
 $(H(\theta) = -(V(\theta))^{-1} = -I(\theta))$ .

Elle est **symétrique** et est définie négative.

Une matrice symétrique est définie négative si ses valeurs propres sont négatives.

## Exercice 5

*Soit  $(x_1, x_2, \dots, x_{10})$  un échantillon de taille  $n = 10$  issu de la loi de poisson de paramètre  $\theta$ . Déterminer un estimateur de  $\theta$  par la méthode de vraisemblance.*

## Exercice 5

Soit  $(x_1, x_2, \dots, x_{10})$  un échantillon de taille  $n = 10$  issu de la loi de poisson de paramètre  $\theta$ . Déterminer un estimateur de  $\theta$  par la méthode de vraisemblance.

On a  $\ell(x_1, x_2, \dots, x_n, \theta) = -n\theta + \ln \theta \sum_{i=1}^n x_i - n \sum_{i=1}^n \ln(x_i)$ .

$$\frac{\partial \ell}{\partial \theta} = 0 \implies -n + \frac{\sum_{i=1}^n x_i}{\theta} = 0.$$

Soit  $\hat{\theta} = \bar{X} = 0.8$ .

Vérifions la condition suffisante:

$$\frac{\partial^2 \ell}{\partial \theta^2} = -\frac{\sum_{i=1}^n x_i}{\theta^2} < 0.$$

```
x=c(1, 1, 1, 1, 0, 0, 0, 0, 1, 3)
```

```
estim=optimise(lPois, c(0,4), maximum = TRUE, x=x)
```

```
estim[[1]]
```

```
[1] 0.8000203
```

```
x=c(1, 1, 1, 1, 0, 0, 0, 0, 1, 3)
```


```
estim=optimise(lPois, c(0,4), maximum = TRUE, x=x)
```

```
estim[[1]]
```

```
[1] 0.8000203
```

Représentons le graphique de la fonction de vraisemblance en fonction de  $\theta$ .

```
theta=seq(0,4,len=100)
y=lPois(theta,x)
plot(theta,y,type="l", col=4,lwd=2)
points(0.8,lPois(0.8,x),col=2, pch=21,lwd=6)
```





## Exercice 6

Soit  $(x_1, \dots, x_{10})$  un échantillon i.i.d de taille  $n = 10$  issu de la loi normale de paramètre  $m$  et  $\sigma^2$ . Déterminer les estimateurs de  $m$  et de  $\sigma^2$  par la méthode du maximum de vraisemblance et calculer la matrice hessienne.  $x_i =$

$(4.634, 1.227, 2.337, 5.241, 3.597, 4.559, 5.912, 1.711, -0.106, -0.195)$ .

## Exercice 6

Soit  $(x_1, \dots, x_{10})$  un échantillon i.i.d de taille  $n = 10$  issu de la loi normale de paramètre  $m$  et  $\sigma^2$ . Déterminer les estimateurs de  $m$  et de  $\sigma^2$  par la méthode du maximum de vraisemblance et calculer la matrice hessienne.  $x_i =$

$(4.634, 1.227, 2.337, 5.241, 3.597, 4.559, 5.912, 1.711, -0.106, -0.195)$ .

On peut vérifier que la vraisemblance de la loi normale est donnée par:

$$\ell(x_1, x_2, \dots, x_n, \theta) = -\frac{n}{2} (\ln(2\pi) + \ln(\sigma^2)) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - m)^2$$

## Exercice 6

Soit  $(x_1, \dots, x_{10})$  un échantillon i.i.d de taille  $n = 10$  issu de la loi normale de paramètre  $m$  et  $\sigma^2$ . Déterminer les estimateurs de  $m$  et de  $\sigma^2$  par la méthode du maximum de vraisemblance et calculer la matrice hessienne.  $x_i =$

$(4.634, 1.227, 2.337, 5.241, 3.597, 4.559, 5.912, 1.711, -0.106, -0.195)$ .

On peut vérifier que la vraisemblance de la loi normale est donnée par:

$$\ell(x_1, x_2, \dots, x_n, \theta) = -\frac{n}{2} (\ln(2\pi) + \ln(\sigma^2)) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - m)^2$$

$$\frac{\partial \ell}{\partial m} = \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - m) = 0 \iff \hat{m} = \bar{X} = 2.8917 \quad (1)$$

$$\frac{\partial \ell}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n (X_i - m)^2 = 0 \iff \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = 4.3941$$

$$\frac{\partial^2 \ell}{\partial m^2} = -\frac{n}{\sigma^2}$$

$$\frac{\partial^2 \ell}{\partial \beta^2} = \frac{n}{2\beta^2} - \frac{2}{\beta^3} \sum_{i=1}^n (X_i - m)^2, \quad (\beta = \sigma^2)$$

$$\frac{\partial^2 \ell}{\partial m \partial \beta} = -\frac{1}{\beta^2} \sum_{i=1}^n (X_i - m)$$

Le hessienne observée est:

$$H = \begin{pmatrix} -\frac{n}{\sigma^2} & -\frac{1}{\sigma^4} \sum_{i=1}^n (X_i - m) \\ -\frac{1}{\sigma^4} \sum_{i=1}^n (X_i - m) & -\frac{n}{2\sigma^4} + \frac{1}{\sigma^6} \sum_{i=1}^n (X_i - m)^2 \end{pmatrix}$$

La hessienne espérée est:

$$\mathcal{H} = \begin{pmatrix} -\frac{n}{\sigma^2} & 0 \\ 0 & -\frac{n}{2\sigma^4} \end{pmatrix} = \begin{pmatrix} -2.275 & 0 \\ 0 & -0.2589 \end{pmatrix}$$

En effet,  $\mathbb{E}\left(-\frac{n}{\sigma^2}\right) = -\frac{n}{\sigma^2}$ ;

$$\mathbb{E}\left(-\frac{1}{\sigma^4} \sum_{i=1}^n (X_i - m)\right) = -\frac{1}{\sigma^4} \sum_{i=1}^n \mathbb{E}(X_i - m) = 0;$$

$$\mathbb{E}\left(\frac{n}{2\sigma^4} - \frac{1}{\sigma^6} \sum_{i=1}^n (X_i - m)^2\right) = \frac{n}{2\sigma^4} - \frac{2}{2\sigma^6} \sum_{i=1}^n \mathbb{E}(X_i - m)^2 = \frac{n}{2\sigma^4} - \frac{2n\sigma^2}{2\sigma^6}.$$

La hessienne espérée est:

$$\mathcal{H} = \begin{pmatrix} -\frac{n}{\sigma^2} & 0 \\ 0 & -\frac{n}{2\sigma^4} \end{pmatrix} = \begin{pmatrix} -2.275 & 0 \\ 0 & -0.2589 \end{pmatrix}$$

En effet,  $\mathbb{E}\left(-\frac{n}{\sigma^2}\right) = -\frac{n}{\sigma^2}$ ;

$$\mathbb{E}\left(-\frac{1}{\sigma^4} \sum_{i=1}^n (X_i - m)\right) = -\frac{1}{\sigma^4} \sum_{i=1}^n \mathbb{E}(X_i - m) = 0;$$

$$\mathbb{E}\left(\frac{n}{2\sigma^4} - \frac{1}{\sigma^6} \sum_{i=1}^n (X_i - m)^2\right) = \frac{n}{2\sigma^4} - \frac{2}{2\sigma^6} \sum_{i=1}^n \mathbb{E}(X_i - m)^2 = \frac{n}{2\sigma^4} - \frac{2n\sigma^2}{2\sigma^6}.$$

**Implémentation sous R:**

```
y=c(4.634, 1.227, 2.337, 5.241, 3.597, 4.559, 5.912,
1.711, -0.106, -0.195)
```

```

lNorm=function(theta,x){ n=length(x)
ss=sum((x-theta[1])^2)
n/2*(log(2*pi)+log(theta[2]))+1/(2*theta[2])*ss }
estim2=optim(fn=lNorm,par=c(0,0.01), x=y, hessian=TRUE,
lower=c(1,1),method="L-BFGS-B")
estim2[[1]]

[1] 2.891700 4.394126

round(estim2[[6]],4)

      [,1] [,2]
[1,] 2.2758 0.000
[2,] 0.0000 0.259

```

## Exercice 7

Soit la régression linéaire simple  $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$  avec  $\varepsilon_i \stackrel{iid}{\sim} N(0, \sigma)$ .  
Donner une estimation ponctuelle des paramètres  $(\beta_0, \beta_1, \sigma)$  par la méthode de vraisemblance.

Application sous R:

$x = (0.1, 0.32, 0.52, 0.66, 0.41, 0.91, 0.29, 0.46, 0.33, 0.65)$

$y = (0.25, 0.81, 1.16, 1.31, 0.7, 1.68, 0.57, 1.2, 0.79, 1)$



## Exercice 7

Soit la régression linéaire simple  $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$  avec  $\varepsilon_i \stackrel{iid}{\sim} N(0, \sigma)$ .  
Donner une estimation ponctuelle des paramètres  $(\beta_0, \beta_1, \sigma)$  par la méthode de vraisemblance.

Application sous R:

$$x = (0.1, 0.32, 0.52, 0.66, 0.41, 0.91, 0.29, 0.46, 0.33, 0.65)$$

$$y = (0.25, 0.81, 1.16, 1.31, 0.7, 1.68, 0.57, 1.2, 0.79, 1)$$

$$\varepsilon_i \stackrel{iid}{\sim} N(0, \sigma) \Rightarrow y_i \stackrel{iid}{\sim} N(\beta_0 + \beta_1 x_i, \sigma), \text{ donc}$$

$$f(y_i) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{1}{2\sigma^2}(y_i - \beta_0 - \beta_1 x_i)^2\right)$$

$$\Rightarrow \log L = -\frac{n}{2} \log(2\pi) - n \log(\sigma) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$$

```

x=c(0.1,0.32,0.52,0.66,0.41,0.91,0.29,0.46,0.33,0.65)
y=c(0.25,0.81,1.16,1.31,0.7,1.68,0.57, 1.2,0.79,1)
# VS
logL=function(x,y,theta){ # theta=(beta0,beta1,sigma)
n=length(x); b0=theta[1]
b1=theta[2]; sig=theta[3]
ll=-n/2*log(2*pi)-n*log(sig)-1/(2*sig^2)*sum((y-b0-b1*x)^2)
return(-ll)}
# Estimation
theta=optim(fn=logL,par=c(1,1,1), x=x,y=y,
lower=c(-Inf,-Inf,0.001), upper=c(Inf, Inf, Inf),
method="L-BFGS-B",hessian=TRUE)
theta[[1]]

[1] 0.1786281 1.6524133 0.1430038

```

Comparons le résultat par rapport l'estimation par la méthode des MCO

```
mco=lm(y~x)
mco[[1]] # coefficients

(Intercept)          x
  0.1786274    1.6524142

summary(mco)[[6]] # sigma

[1] 0.1598768
```

La matrice des variances-covariances des paramètres:

```
vcov(mco)           # par MCO

              (Intercept)              x
(Intercept)  0.01408352 -0.02479024
x            -0.02479024  0.05331235

round(solve(theta[[6]]),6) # MVS (Hessienne)

      [,1]      [,2]      [,3]
[1,]  0.011268 -0.019834  0.000000
[2,] -0.019834  0.042653  0.000000
[3,]  0.000000  0.000000  0.001022
```

## ① Vocabulaires

## ② Propriétés d'un estimateur

## ③ Méthodes d'estimation

La méthode de vraisemblance

Méthode des moments

Méthode des MCO

## Définition 10

①  $\mathbb{E}(X^k)$  est le *moment théorique non centré* d'ordre  $k$ .

## Définition 10

- ①  $\mathbb{E}(X^k)$  est le **moment théorique non centré** d'ordre  $k$ .
- ②  $\mathbb{E}[(x - m)^k]$  est le **moment théorique centré** d'ordre  $k$  où  $m = \mathbb{E}(X)$ .

## Définition 10

- ①  $\mathbb{E}(X^k)$  est le **moment théorique non centré** d'ordre  $k$ .
- ②  $\mathbb{E}[(x - m)^k]$  est le **moment théorique centré** d'ordre  $k$  où  $m = \mathbb{E}(X)$ .
- ③  $M_k = \frac{1}{n} \sum_{i=1}^n X_i^k$  est le **moment empirique non centré** d'ordre  $k$ .



## Définition 10

- ①  $\mathbb{E}(X^k)$  est le **moment théorique non centré** d'ordre  $k$ .
- ②  $\mathbb{E}[(X - m)^k]$  est le **moment théorique centré** d'ordre  $k$  où  $m = \mathbb{E}(X)$ .
- ③  $M_k = \frac{1}{n} \sum_{i=1}^n X_i^k$  est le **moment empirique non centré** d'ordre  $k$ .
- ④  $\mu_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$  est le **moment empirique centré** d'ordre  $k$ .

## Définition 10

- ①  $\mathbb{E}(X^k)$  est le **moment théorique non centré** d'ordre  $k$ .
- ②  $\mathbb{E}[(X - m)^k]$  est le **moment théorique centré** d'ordre  $k$  où  $m = \mathbb{E}(X)$ .
- ③  $M_k = \frac{1}{n} \sum_{i=1}^n X_i^k$  est le **moment empirique non centré** d'ordre  $k$ .
- ④  $\mu_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$  est le **moment empirique centré** d'ordre  $k$ .

## Définition 10

- ①  $\mathbb{E}(X^k)$  est le **moment théorique non centré** d'ordre  $k$ .
- ②  $\mathbb{E}[(x - m)^k]$  est le **moment théorique centré** d'ordre  $k$  où  $m = \mathbb{E}(X)$ .
- ③  $M_k = \frac{1}{n} \sum_{i=1}^n X_i^k$  est le **moment empirique non centré** d'ordre  $k$ .
- ④  $\mu_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$  est le **moment empirique centré** d'ordre  $k$ .

La méthode des moments consiste à **égaliser** entre les moments théoriques et les moments empiriques.

## Exemple 3

Soit  $(X_1, X_2, \dots, X_n)$  une suite de v.a iid suivant la loi de  $\mathcal{B}(1, p)$ .

Déterminer l'estimateur de  $p$  par la méthode des moments.

On a  $\mathbb{E}(X) = p$  et  $M_1 = \bar{X}$ , d'où  $\mathbb{E}(X) = M_1 \implies \hat{p} = \bar{X}$ .

## Exemple 4

Soit  $(X_1, X_2, \dots, X_n)$  une suite de v.a telle que  $X_i \stackrel{iid}{\sim} N(m, \sigma)$ . Donner une estimation des paramètres  $m$  et  $\sigma^2$  par la méthode des moments.

$$\mathbb{E}(X) = M_1 \implies \hat{m} = \bar{X}.$$

$$\mathbb{E}(X^2) = M_2 \implies \sigma^2 + m^2 = \bar{X}^2 \implies \sigma^2 = \bar{X}^2 - m^2. \text{ Soit}$$

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \hat{m}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

**Remarque:** On peut, aussi, égaliser entre les moments centré théoriques et empiriques afin de déterminer l'estimateur de  $\sigma^2$ .

## ① Vocabulaires

## ② Propriétés d'un estimateur

## ③ Méthodes d'estimation

La méthode de vraisemblance

Méthode des moments

Méthode des MCO

La méthode des MCO consiste à minimiser l'erreur quadratique (EQ).

Soit le modèle linéaire simple  $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$ . L'erreur quadratique correspondant à ce modèle est donné par:

$EQ = \sum_{i=1}^n \varepsilon_i^2 = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$ . Les estimateurs de  $\beta_0$  et  $\beta_1$  sont solution de la fonction objective  $\min_{\beta_0, \beta_1} EQ$ .

La condition nécessaire est:

$$\frac{\partial EQ}{\partial \beta_0} = \frac{\partial EQ}{\partial \beta_1} = 0$$

Et la condition suffisante est: la matrice Hessienne est définie positive.

On peut montrer que les estimateurs des paramètres sont donnés par:

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} \quad \text{et} \quad \hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

Dans le cas du modèle de régression multiple, on aura  $\hat{\beta} = (X'X)^{-1}X'Y$  et la matrice des variances-covariances des paramètres est estimée par  $\hat{\Sigma} = \hat{\sigma}_\varepsilon^2 (X'X)^{-1}$ .

## Exercice 8

*Reprenez l'exercice 7 et déterminer les estimateurs du modèle par la méthode des MCO.*